EulerPilot v2 设计文档

文档名称	EulerPilot v2 设计文档
文档版本	v1.1
文档类型	设计文档
文档状态	正式发布
适用对象	评审专家、架构评审、接手开发的工程师
维护团队	三驱兄弟(西安邮电大学)
验收系统	openEuler 24.03 LTS-SP3,内核 `6.6.0-schedpilot-sp3`
更新日期	2026-10-25
对应代码	`src/`、`sched/`、`design/`(commit 级溯源见 `PROVENANCE.md`)

本文件记录控制面的架构、模块、契约、关键流程与设计决策。设计总纲(含完整取舍讨论)见 `docs/v2_redesign_2026.md`,接口契约见 `design/INTERFACES.md` 与 `docs/p1/ABI_FREEZE.md`;本文是面向评审的浓缩版,结构与实现一一对应。

目录

1. 文档背景
2. 设计目标与约束
3. 总体架构
4. 模块设计
5. 数据契约
6. 关键流程时序
7. 安全与权限模型
8. 设计决策记录
9. 与参考工作的关系
10. 修订记录

1. 文档背景

EulerPilot v2 是面向 openEuler 的资源管控 Agent(赛题 proj2)。它要在真实的 sched_ext 内核上完成”感知 → 决策 → 执行 → 恢复”的闭环,同时保证任何软件故障都不会把系统留在未知的调度状态里。实现一份策略容易,难的是让策略的每一次生效都可验证、每一次失效都可恢复、每一次自动化都有边界。

本仓库为此重新设计了控制面:**策略全部声明式、写者唯一、变更全事务化、观测只能收紧**。三个设计前判决定了后续所有取舍:

1. SP3 是唯一验收级系统(SP4 实测 cgroup v1 且无 PSI,只能记 UNSUPPORTED);
2. BG 是业务角色、LAT/COMPUTE/CACHE 是运行特征,两个维度正交,不得互相推断;
3. 自适应动作必须被租约、门控与抑制三层约束,自动化不获得额外权限。

表 1 本文与实现材料的对应关系

主题	本文位置	一手材料
分层与模块边界	第 3、4 章	`src/`、`include/ep/`
契约字段与取值	第 5 章	`design/schemas/*.json`、`design/INTERFACES.md`
事务与恢复语义	第 6 章	`docs/p1/ABI_FREEZE.md`、`src/executor/`
权限与自动化边界	第 7 章	`src/core/`、`experiments/fail_safe_matrix_sp3.sh`
决策与备选方案	第 8 章	`docs/v2_redesign_2026.md`、`evidence/`

2. 设计目标与约束

表 2 设计目标

编号	目标	验证方式	结果
G1	策略生效与回退全事务,崩溃后可恢复	fail-safe 矩阵 17 条目	17/17(run8 + 冻结构建 run9/10/11)
G2	内核状态自证(读回而非推断)	集成测试断言 map/文件内容	8 项集成全过,0 SKIP
G3	自动化动作有三层边界(权限/证据/抑制)	门控注入实验 + 单元门控矩阵	门控被量化为”延迟器”(约 40s)
G4	性能结论可复现	预注册矩阵 + 冻结二进制复跑	冻结构建复现 +1.83% [1.38, 2.26]
G5	扩展新资源域只需新 Skill,不动核心	cgroup 域与事件链的实际接入	核心事务代码未因扩展而修改
G6	失败可诊断、可追溯	WAL + 逐轮哈希 + 逐请求原始件	`PROVENANCE.md`、`evidence/`

表 3 硬约束

约束	来源	对设计的影响
主验收系统为 openEuler 24.03-LTS-SP3	赛题要求	所有结论以 SP3 为准,其他系统只作参考
Linux 同时只允许一个 sched_ext 调度器	内核行为(第二次 struct_ops 注册返回 EBUSY)	与参考实现 schedpilotd 互斥运行;apply 前检查在位状态
CPU 下线会注销当前调度器	内核行为(hotplug_seq 变化,enable_seq 不变)	在位性判定不能只看计数器;S15 场景专门断言检出与补偿
内核在 state 可读之后才递增 scx_enable_seq	kernel/sched/ext.c:5503-5518	采用等值判定 + 发布等待,否则误报 changed
策略生成限于声明式白名单,不在线编译内核代码	安全边界	参数有界、专家档位枚举、BPF 对象预构建并哈希入档
内核多子系统之间不存在原子事务	系统现实	跨域变更按 saga 处理,补偿失败保留现场
测量存在窗间噪声	实测 p99 极差/均值 46%	比较类判定先声明分辨率,不足则 not run

3. 总体架构

3.1 三层结构



3.2 架构规则

表 4 规则与执行机制

规则	机制	违反时的行为
决策层不持特权	Agent/实验脚本/LLM 通道只能提交策略	绕过通道无处可写(socket 0600 + peer uid)
执行层互斥	flock 状态目录 + 租约三态 + 世代号	第二实例拒绝启动;旧请求 GENERATION_CONFLICT
数据层可验证	调度器在位性由 state/ops/enable_seq 联合判定;cgroup 一律读回;class 撤销用 class-get 确认	读回不符 → 补偿回退并 VERIFY_FAILED
kind 与实例域匹配	apply 前按 kind 分派校验	不匹配零副作用 REJECTED + UNSUPPORTED
观测只能收紧	门控只返回拒绝,放行由权限与证据决定	断供时拒绝动作并报告高水位
拆除优先于建立	存储不可写时授”仅内存租约”	拆效应放行;建新效应 RECOVERY_REQUIRED

3.3 模块依赖

表 5 依赖方向(自上而下,不存在反向依赖)

模块	依赖	被依赖
src/cli	Unix socket 协议	用户/脚本
src/executor	src/core、src/skills	—
src/core	无特权系统调用只读	src/executor
src/skills	src/core、ep-schedctl、loader、cgroup 文件系统	src/executor
src/evtmon	BPF skeleton、event.observe	—
sched/	内核 BTF、libbpf(静态)	src/skills

4. 模块设计

4.1 CLI 客户端(src/cli/main.cpp)

10 个子命令,每个都建立一次性 AF_UNIX 连接、写一行 ND-JSON、读一行响应(1 MiB 上限),把响应以缩进 JSON 打印。退出码:0 仅当状态属于 OK/VERIFIED/APPLIED/ROLLED_BACK;其他为 1;参数错误为 2。

表 6 子命令与协议映射

命令	协议 op	读写
ep status	policy.status	读
ep features	feature.snapshot	读
ep route	route.decide	读
ep slo --expert E	slo.evaluate	读
ep observe --file F	service.observe	摄取(不推进世代号)
ep reconcile	transaction.reconcile	写
ep validate --file F	policy.validate	读
ep lease [--ttl-ms N] [--owner O]	lease.acquire	写
ep apply (--file|--intent-file) [--idempotency-key K]	policy.apply	写

命令	协议 op	读写
ep rollback --of … --transaction … --snapshot … --policy-sha256 …	policy.rollback	写

socket 路径解析顺序:$EP_SOCKET → /run/eulerpilot-v2/executor/executor.sock → $XDG_RUNTIME_DIR/eulerpilot-v2/executor/executor.sock → /tmp/eulerpilot-v2-<uid>/executor.sock。apply/rollback 会先自动取租约,再生成信封(req-*/txn-* 随机标识、issued_at=now、deadline=now+60000)。

4.2 执行服务(src/executor/)

表 7 组件与职责

组件	文件	职责
Ownership	ownership.cpp	flock、租约、fence、世代号持久化到 state.json
Journal	journal.cpp	只追加 WAL,每次 append 后 fsync;启动时截断撕裂尾行
事务引擎	executor.cpp	校验、授权、快照、生效、验证、提交、补偿、幂等重放
监控线程	executor.cpp	50ms tick;1s 特征采样、1s 在位探测(连续 3 次失败才回退)、2s 刷新、2s 自动通道与事件守卫
shutdown	executor.cpp	收到停止信号先走同一条补偿回退(含 verify_rolled_back)再退出

事务状态机(日志类型):

```
PREPARED → APPLYING → VERIFYING → VERIFIED → COMMITTED
                                  ↘ COMPENSATING → ROLLED_BACK
                                  ↘ RECOVERY_REQUIRED(补偿失败,保留现场)
ROLLBACK_PREPARED → …(人工回退路径)    RESULT(每次动作的最终回执)
```

租约三态:无人持有 / 他人持有(拒绝动作)/ 自动通道持有(须显式交接)。世代号只在 COMMITTED 时推进,REJECTED 不推进(S08/S10/S17 均断言此点)。

4.3 核心逻辑(src/core/)

表 8 核心组件

组件	文件	要点
策略校验	policy.cpp + policy_json.hpp	schema 之外的语义规则:切片关系、heartbeat_timeout>period、policy_ttl>min_dwell、max_age≤heartbeat_timeout、目标去重、class=BG ⇔ role=BACKGROUND
cgroup 策略校验	cgroup_policy.cpp	effects 1–8、路径段拒绝 ./..、重复路径拒绝、TTL ≥10s
目标绑定	target.cpp	O_PATH|O_NOFOLLOW FD + kernfs inode/cgroup_id;pidfd + starttime;退出/重建/迁出即失效
特征窗	features.cpp	cpu_busy_pct/load1/psi_cpu_some_avg10,带 valid/age/来源;样本 ≥3 才算充分;run_delay 未采样
路由	router.cpp	阈值 + 5s 滞回,advisory 输出档位与理由
SLO 门控	slo.cpp	服务半区 + 宿主半区 + 绝对上限 + 分辨率护栏;观测契约严格键校验与新鲜度判定
AutoPilot	autopilot.cpp	白名单专家 + 三层抑制(驻留/候选保持/预算)
事件守卫	event_guard.cpp	arm 解析、持续/回落连续窗计数、纯化判定函数
域与工具	domain.cpp、util.cpp	状态与错误码字符串、SHA-256、规范 JSON、RFC3339

4.4 调度 Skill(src/skills/sched_skill.cpp + sched/)

loader 进程完成 struct_ops 注册后,把 link fd 经 SCM_RIGHTS(带 CLOEXEC)交给执行服务并退出;此后调度器生命周期归执行服务所有——执行服务崩溃即调度器分离,不留孤儿。

表 9 sched 域操作与自证

操作	实现	自证方式
挂载	ep-sched-loader --mode …	state/ops=eulerpilot/ena

操作	实现	自证方式
	`--pin-dir … --fd-socket …`	`ble_seq` 三项等值判定(含发布等待)
写 cfg	`ep-schedctl set`(短命子进程)	写前快照、写后 `get` 读回
写 class	`ep-schedctl class-set --pid … --class …`	`class-get` 读回;NORMAL 不写条目
撤销 class	`class-del`	再 `class-get` 确认不存在,否则记 `class revocation unconfirmed`
漂移纠正	刷新周期 cfg 全量再断言;class 条目按轮换抽样	纠正时打印 `cfg drift corrected` / 抽样纠正日志
崩溃恢复	扫 pin 目录与 `sched-runtime.json` 的 `classified` 重建受管集合	孤儿条目撤销;外域资源不动并回报 conflict

`--skill sched-ref` 是同接口的对照实现(loader 作为子进程常驻),用于证明 FD 传递路径的差异不改变 fail-safe 语义(SO5 使用它)。

4.5 cgroup Skill 与事件守卫(`src/skills/cgroup_skill.cpp`)

`cpu_weight → 内核写入值` 的翻译**只发生在 `plan()` 一处**,后续状态一律使用翻译后的 `desired`,避免两处口径不一致(该项曾在真机上把 0 写进内核)。写入必须 `O_WRONLY|O_TRUNC`:缺少 `O_TRUNC` 时把 `200` 改成 `50` 会读回 `500`。

表 10 cgroup 域不变量

不变量	保证手段
快照先于写入	读不到原值即 fail-closed,不进入 apply
marker 独立落盘	`<state-dir>/cgroup-effects.json` 记录 path/file/previous/desired 与动作 ID
效果不叠加	已有在位效应时第二次 apply 被拒
漂移可纠正	每刷新周期复查(文件读取代价低,可全量)
崩溃可恢复	重启时按 marker 恢复原值并清理 marker,日志 `recovered N cgroup effect(s)`
事件授权不转移	watch 以 path + kernfs id 双匹配;重建即 `WATCH_REBUILT` 并回退

事件链数据通路:events_trace.bpf.c(raw tracepoint,按 cgroup kernfs id 聚合唤醒等待,start_time 比对排除 PID 复用)→ ep-evtmon(只读泵,窗口排空 + id 解析回路径 + event.observe 上报)→ event_guard(证据门与滞回)→ 标准 apply/rollback。泵的开销与丢弃率已实测:0.5% 单核、12.1k 事件/s、pid 复用丢弃 0、聚合丢失 0 (evidence/p4/pump-overhead-20261025.txt)。

4.6 数据面(sched/)

struct_ops 名 eulerpilot,接口版本 SP_INTF_VERSION 3,模式 basic/class/adaptive, 标志位 CLASS_DSQ/PREEMPT/LLC_AFFINITY/BG_CONTAIN/CLASSIFY。

表 11 map 清单

map	类型与容量	用途
sp_cfg	ARRAY × 1	切片、抢占阈值、bg vtime、LAT 预算等运行参数
class_map	HASH 16384	tgid → 运行分类 (LAT/COMPUTE/CACHE/BG)
tg_stats	HASH 32768	线程组统计
task_ctx	TASK_STORAGE(BPF_F_NO_PREALLOC)	任务级调度上下文
cpu_llc	ARRAY 1024	CPU → LLC 域映射
stats	PERCPU_ARRAY(40 项)	调度事件计数
pcpu_state	PERCPU_ARRAY × 2	每 CPU 状态
fair_budget	PERCPU_ARRAY	与 CFS 的预算共存记账
wakeup_start	HASH 65536(事件对象)	唤醒时间戳暂存
wait_agg	HASH 4096(事件对象)	每 cgroup 等待聚合(上限 4096 个 cgroup)
evt_stats	ARRAY 4(事件对象)	泵侧统计:追踪数、聚合数、丢弃数

表 12 关键参数(intf.h 默认值与边界)

参数	范围	默认	说明
lat_budget_pct	1–95	60	LAT 份额意图;实际份额由片长比表达
budget_window_ms	10–10000	100	预算窗口
aging_ms	1–5000	20	等待老化,防饥饿

参数	范围	默认	说明
SP_HEARTBEAT_TIMEOUT_NS	固定 2e9	—	仅 adaptive 路径读取(v2 不启用 adaptive)

数据面两处关键修复来自真机根因分析:绑核任务(nr_cpus_allowed==1)直投本机 local DSQ 并 SCX_KICK_IDLE(修复前 6/6 触发 runnable task stall,修复后 3×90s 零失速);LAT 份额按 lat_slice = comp_slice × pct / (100 − pct) 换算(60% 预算实测 57.9–58.5%)。

5. 数据契约

所有契约位于 design/schemas/,JSON Schema Draft-07、additionalProperties:false;示例位于 design/examples/。设计自检 scripts/validate_design.py 强制 6 个正例通过、 27 个反例被拒。

表 13 契约清单

契约	kind	必填/关键约束
scheduling-policy.schema.json	SchedulingPolicy	spec 需 scope/mode/expert/source/targets/parameters/safety;targets 1–64;安全字段全部必填
cgroup-policy.schema.json	CgroupPolicy	scope=cgroup-effects;effects 1–8;cpu_weight 1–10000;policy_ttl_ms 10000–3600000
event-arm.schema.json	EventArm	watch;threshold_wait_ms 1–60000;sustain/release 1–10;action.cpu_weight
action-envelope.schema.json	—	11 个必填字段;operation ∈ policy.apply/policy.rollback;policy_sha256 64 位小写十六进制;回滚必须带 rollback_of
skill-manifest.schema.json	SkillManifest	能力与生命周期声明;execution=privileged-executor-only;apply 必须伴随 snapshot/verify/rollback/reconcile

表 14 协议 op 与消息要点

op	是否需要信封	要点
policy.status / feature.snapshot / route.decide	否	只读,响应 status:"OK"
slo.evaluate	否	入参 expert,可选 max_observation_age_ms
service.observe / event.observe	否	严格键集校验;观测过旧(>600s 或 >10×窗口)或未来(>5s)拒绝
lease.acquire	否	lease_owner 8–128(缺省 agent-<hex6>)、lease_ttl_ms ≥1000
policy.validate	否	dry-run:校验 + 目标解析 + 摘要
policy.apply / policy.rollback / transaction.reconcile	是	信封 11 字段齐备,apiVersion 必须等于 eulerpilot.io/v1alpha1,deadline > issued_at

表 15 响应状态与错误码

类别	取值
状态	OK(只读成功)、VERIFIED、REJECTED、ROLLED_BACK、DEGRADED、RECOVERY_REQUIRED
错误码	SCHEMA_INVALID、UNSUPPORTED、PERMISSION_DENIED、TARGET_STALE、OWNERSHIP_CONFLICT、GENERATION_CONFLICT、DEADLINE_EXCEEDED、SLO_DENIED、APPLY_FAILED、VERIFY_FAILED、ROLLBACK_FAILED、RECOVERY_REQUIRED、IDEMPOTENCY_CONFLICT、INTERNAL

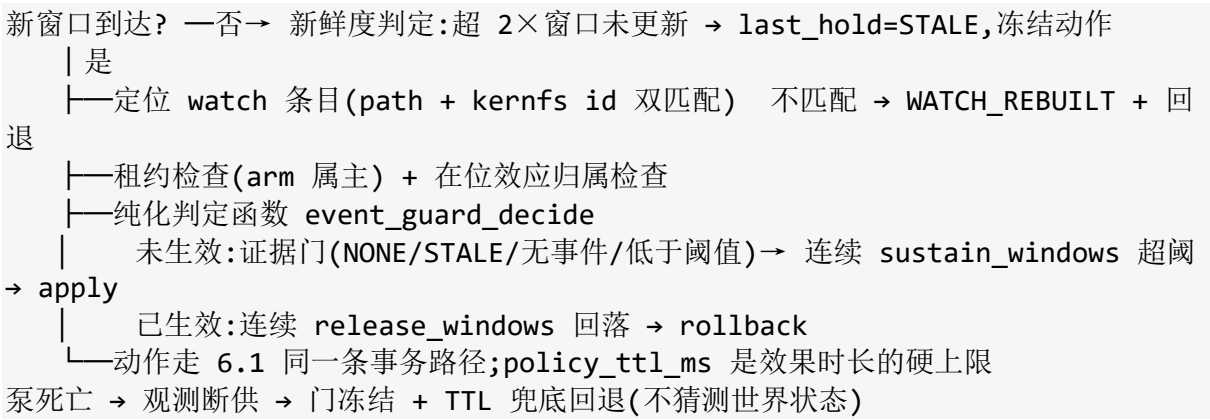
契约演进规则:字段变更必须同步 schema、示例、校验脚本与文档四处;ABI_FREEZE.md 冻结的字段语义不得静默改变,新增可选字段需在 P1 报告登记(如 lease_persisted、store_warning)。

6. 关键流程时序

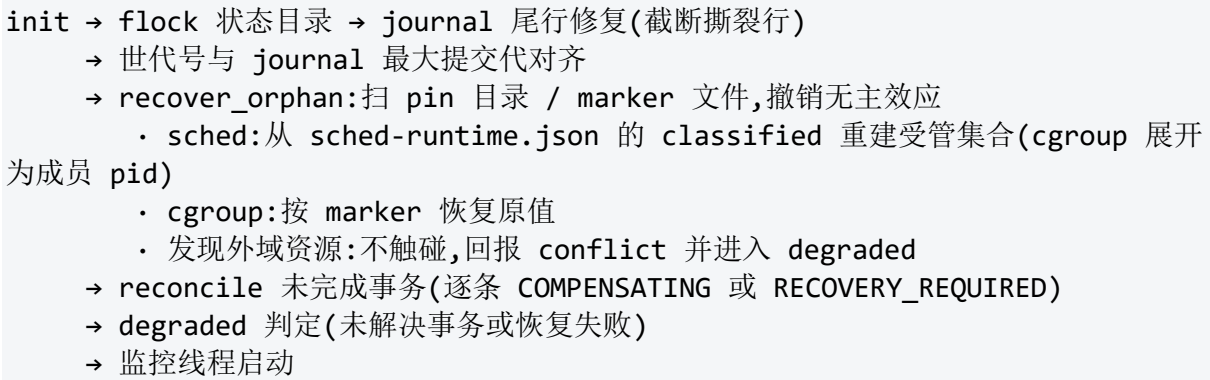
6.1 策略生效(policy.apply)



6.2 事件守卫(监控线程,2s 周期)



6.3 崩溃恢复(重启)



停止路径与崩溃路径不同:shutdown() 先执行一次完整补偿回退(含 verify_rolled_back)再清理 pid 与 socket,因此正常停止不会留下 pin(run2 曾泄漏 5 个 map pin,已修复)。

7. 安全与权限模型

表 16 权限层次

层	持有	边界
决策层	无特权	只能提交策略;观测摄取不推进世代号;source=llm-proposal 必须过门控
执行层	BPF/cgroup 写权限	socket 0600 + SO_PEERCRED 同 uid 限定(仅 --allow-any-uid 放宽);每连接 5s 接收超时
数据层	内核	所有写入读回自证;link FD 随进程死亡失效

表 17 自动化边界三例

自动化通道	开启方式	权限来源	失败时的默认
AutoPilot 专家切换	--auto-apply --auto-policy F --auto-owner ID	必须由该属主持有租约	不动作
事件驱动调权	--skill cgroup --event-arm arm.json	arm 属主租约 + 新鲜观测 + 人工阈值授权	门冻结
策略 TTL	策略内 policy_ttl_ms	声明即上限	到期自动回退

其他安全要点:目标路径解析防符号链接(O_NOFOLLOW)与越权;schema 正则不替代文件描述符与内核身份验证;租约与 fence 防止过期凭证覆盖新状态;RECOVERY_REQUIRED 期间拒绝一切新建效应,只放行拆除。

8. 设计决策记录

表 18 决策记录(按时间)

决策	备选	选择理由与证据
唯一特权写者 + 声明式契约	各组件直写内核	第二写者在结构上不可构造;负路径矩阵 S08–S11 验证
link FD 经 SCM_RIGHTS 移交后 loader 退出	loader 常驻	执行服务崩溃即调度器分离,不留孤

决策	备选	选择理由与证据
		儿;integration_fd
enable_seq 等值判定 + 发布等待	计数器递增即信任	内核在 state 可读之后才递增 (kernel/sched/ext.c:5503–5518);曾致 7 次验收败 2
绑核任务直投本机 local DSQ + SCX_KICK_IDLE	唤醒 idle CPU 等拉取	6.6 内核把不允许的拉取改投全局 DSQ;修复前 6/6 失败 → 3×90s 零失速
LAT 份额用片长比表达	直接写百分比	份额由片长比决定;60% 预算实测 57.9–58.5%
BG 与运行特征正交	按 CPU 占用推断角色	业务角色须显式授权;class=BG ⇔ role=BACKGROUND 为校验不变量
观测只能收紧	观测可放行	噪声与断供两种失败模式下,放行会把误报变成动作
比较类判定声明分辨率	直接判	同状态 p99 窗间噪声 46% ≫ 声明预算 5%
失效方向不对称(拆放行/建拒绝)	写失败一律拒绝	盘满时仍能安全回退;S14 与 ABI_FREEZE.md §6 第 8 条
class 撤销必须读回确认	只看 cfg.flags	协议 §8 要求检查旧 class/vtime/slice;class revocation unconfirmed 日志
class 逐条漂移按轮换抽样纠正	全量再断言 / 不纠正	全量读回在 16k 条目下不可负担;抽样 + cfg 全量的组合成本实测约 5ms/次
泵死亡 = 门冻结	忽略断供	断供后世界状态未知;冻结 + TTL 兜底保持安全侧
跨域失败按 saga 处理	承诺原子事务	内核子系统间无原子性;补偿失败保留现场并 RECOVERY_REQUIRED
事件链动作复用标准事务路径	泵直接写 cgroup	保持唯一写者;integration_events 第六相亲测泵零写入

9. 与参考工作的关系

表 19 来源与边界

来源	复用内容	本项目新增	许可与溯源
SchedPilot(前作)	BPF 数据面骨架与实验方法(sched/,源提交 0aeca0c)	控制面、执行服务、CLI、事件链、恢复语义	GPL-2.0;逐文件哈希见 sched/README.md、PROVENANCE.md
EulerPilot(v1)	Skill 与审计思路	代码未复用;契约、租约/世代号、WAL、fail-safe 全部重写	见 docs/audits/ 审计记录
上游 sched_ext	内核框架与 scx 头文件	自建调度器 eulerpilot 与 loader	内核头文件随源码归档
公开文献(Towards Agentic OS、MoS/ASA)	专家路由、SLO 门控思想	增量在约束链、发布一致性与实测闭环	一手链接核验见 docs/research/sources.md
参考实现 schedpilotd	作为 E 臂对照(互斥运行)	新旧控制面一致性验证(GET +1.92% vs 本项目 C +1.83%)	evidence/p2/earms-20261025.txt

归属纪律:思想来源与代码来源分别标注;凡派生文件记录源版本与哈希;性能对照显式说明互斥运行条件;公开化历史(如镜像分支的历史重写)在 PROVENANCE.md 披露。

10. 修订记录

版本	日期	内容	作者
v1.0	2026-10-25	随交付创建	三驱兄弟
v1.1	2026-10-25	扩充:模块增至六个(CLI/执行服务/核心/调度 Skill/cgroup 与事件/数据面)、依赖表、map 与参数表、协议 op 与错误码表、三处时序补全、决策记录增至 14 条并附证据	三驱兄弟