EulerPilot v2 项目说明书

文档名称	EulerPilot v2 项目说明书
文档版本	v1.1
文档类型	项目说明书(总览)
文档状态	正式发布
适用对象	评审专家、验收人员、接手开发的工程师、新成员交接
维护团队	三驱兄弟(西安邮电大学)
参赛信息	2026 年全国大学生计算机系统能力大赛操作系统设计赛(功能挑战赛道)proj2 · 队伍编号 T2026116649912743
验收系统	openEuler 24.03 LTS-SP3,内核 `6.6.0-schedpilot-sp3`
更新日期	2026-10-25
配套文档	设计文档 / 用户手册 / 部署文档 / 测试文档 / `docs/REPORT.md` / `docs/ACCEPTANCE_20261025.md`

本文回答四个问题:是什么、为什么做、能做什么、结论是什么。所有数字均来自仓库内证据文件(随行标注文件名);未实测的不写百分比;做不到的写 UNSUPPORTED 并给理由。深入材料见第 11 章文档索引。

目录

1. 文档背景与阅读路径
2. 项目背景
3. 系统概述
4. 总体架构
5. 功能说明
6. 关键设计决策
7. 运行环境与交付物
8. 适用范围与不支持项
9. 结论与后续工作
10. 术语表
11. 文档索引
12. 修订记录

1. 文档背景与阅读路径

本仓库是参加 2026 年全国大学生计算机系统能力大赛操作系统设计赛(中西部与华南区域赛,功能挑战赛道)的参赛项目,选题 proj2《面向 openEuler 的自适应资源管控 Agent》。赛题要求在 openEuler 24.03-LTS-SP3 上构建可扩展的用户态 Agent,感知 workload 特征并按负载动态选择资源策略,重点经由 sched_ext 改善 CPU 调度,并支持 eBPF 扩展连接 cgroup 等资源域。

表 1 本文与各分册的分工

文档	定位	典型读者动作
本文(项目说明书)	总览:是什么、为什么、能做什么、结论	10 分钟建立整体认知
docs/设计文档.md	架构、模块、契约、时序、决策记录	评审架构合理性、二次开发
docs/用户手册.md	日常操作:启动、写策略、看状态、排障	上手运行系统
docs/部署文档.md	镜像部署与源码构建(含实测陷阱)	复原环境
docs/测试文档.md	六层测试体系与逐条结果	核对结论来源
docs/ACCEPTANCE_20261025.md	R1–R10 逐条验收判定与边界	对照赛题打分点
docs/REPORT.md	按大赛文档大纲组织的参赛文档	评委通读
PROVENANCE.md	逐轮二进制哈希、来源与归属	溯源审查

表 2 阅读路径建议

你想解决的问题	建议阅读顺序
快速判断项目做到什么程度	本文 3.4 量化结论 → 3.5 阶段完成度 → 第 9 章
理解为什么这样设计	本文第 6 章 → docs/设计文档.md 第 8 章
复现性能数字	本文 5.4 → docs/测试文档.md 第 7 章 → docs/EXPERIMENT_PROTOCOL.md
部署一套新环境	docs/部署文档.md 第 4/5 章 → 第 6 章验证
动手跑一次演示	docs/用户手册.md 第 2 章

你想解决的问题	建议阅读顺序
查某条故障怎么恢复的	本文 5.5 → `docs/p1/P1_EXIT_REPORT.md`

2. 项目背景

2.1 问题场景

服务器上同时运行多个业务时,CPU 调度策略直接决定前台服务的延迟和后台任务的进度。默认调度器对所有任务一视同仁,无法区分”延迟敏感的在线服务”和”不着急的批处理任务”;而调度策略的调整在传统内核里意味着改代码、重启甚至换内核。

表 3 痛点与本项目对策

现实痛点	现有做法的局限	本项目的对策
前台延迟与后台吞吐互相拖累	CFS 只看 nice/cgroup 权重,不看业务角色	声明式策略给出角色与运行特征,数据面按类切片与预算
调度策略调整成本高	改内核调度器需重编与重启	sched_ext 在运行时挂载/卸载 BPF 调度器(struct_ops)
裸用 sched_ext 风险大	直接写 map、无人审计、崩了留孤儿调度器	唯一特权写者 + 事务 + 读回自证 + 崩溃恢复
多来源都能改内核	Agent、脚本、LLM 各写各的,状态不可知	所有变更收进同一条 lease/generation/WAL 通道
性能结论不可信	挑好的数字报、失败轮删掉	预注册协议 + 配对 bootstrap + 负结果与失败现场全留
扩展到新资源域容易失控	每加一个域就多一个写者	Skill 生命周期契约,cgroup 域接入未改核心代码

sched_ext 提供了内核侧入口,但要安全使用它需要完整控制面:**谁能改、怎么改、改坏了怎么恢复**。EulerPilot v2 就是这个控制面加上一个自建数据面。

2.2 目标落成四条可验收指标

1. **真实闭环**:sched_ext 调度器在 SP3 上真实挂载、验证、回退,内核状态自证;
2. **工程可靠**:唯一特权写者、声明式契约、崩溃可恢复(fail-safe 矩阵 17 条目);
3. **性能可证**:预注册实验协议下的配对统计结论,含负结果与阈值敏感性;
4. **扩展完整**:R5 的 hook → 决策 → 动作 → 恢复 完整链路真机跑通。

2.3 赛题要求映射

表 4 R1–R10 判定(逐条依据见 docs/ACCEPTANCE_20261025.md)

编号	赛题要求	状态	一句话依据
R1	可扩展 Agent/Tool/Skill 规范	**达成**	5 个版本化契约 + EventArm,两个效果域,8 个必测集成项
R2	workload 感知与策略动态调整	**达成**	FeatureWindow/路由/门控/两条观测线真机闭环
R3	sched_ext 真实闭环	**达成**	FD 传递挂载 + 内核自证 + fail-safe 17/17
R4	性能提升且可复现	**达成(带边界)**	冻结构建复现 C vs A0 GET +1.83% [1.38, 2.26],20/0
R5	eBPF 扩展连接其他资源域	**达成**	事件链六相真机时间线(2026-10-25 补齐感知端)
R6	创新性	**达成(由消融支撑)**	收益归因链闭合;门控/补偿/身份失效均量化
R7	功能完整性	**达成**	负路径矩阵全覆盖,UNSUPPORTED 不遮盖
R8	性能提升(评分项)	**达成(带边界)**	同 R4,阈值敏感性同报
R9	代码质量	**达成**	587 单测断言、ctest 8/8、GPL-2.0 + NOTICE + 逐轮哈希
R10	演示效果	**达成**	八步演示连续三次彩排全过,收尾干净

3. 系统概述

3.1 核心能力

表 5 能力清单

能力	说明	入口	验证层
调度策略管控	声明式策略驱动调度器挂载、参数写入、分类路由、验证与回退	`ep-executord --skill sched` + `ep apply`	集成 `integration_fd`、fail-safe S01/S02
cgroup 资源管控	`cpu.weight` 快照、写入、读回验证、漂移纠正、崩溃恢复	`--skill cgroup` + `CgroupPolicy`	集成 `integration_cgroup`
事件驱动防护	BPF 采集每 cgroup 唤醒等待,超阈值自动调权,条件消除即补偿	`--event-arm` + `ep-evtmon`	集成 `integration_events`(六相)
负载感知	FeatureWindow 窗口化采集 CPU/load/PSI,带 valid/age/来源	`ep features`	单元(指标有效性)
专家路由	阈值 + 5s 滞回给出专家档位建议(advisory)	`ep route`	单元(路由真值表)
SLO 门控	服务半区 + 事件半区双通道,只能让门更严,带分辨率护栏	`ep slo` / `ep observe`	单元 + 门控注入实验
自动切换	AutoPilot 在显式开启后按租约动作,三层抑制	`--auto-apply` 一组参数	集成 `integration_lease/integration_ttl`
故障恢复	17 类故障场景自动回退,残余由内核 map 自证清除	内置(监控线程 + 启动 reconcile)	fail-safe 矩阵
审计与溯源	只追加 WAL、逐轮二进制哈希、逐请求原始数据	`journal.jsonl` / `PROVENANCE.md`	一键验收包校验

3.2 工作原理(一段话版)

执行服务 `ep-executord` 启动后独占状态目录(flock)。用户通过 CLI 提交声明式策略(JSON 文件),策略先过 schema 与语义校验,再由执行服务在租约与世代号保护下走事务流程:快照当前值 → 写前日志 → 生效 → 读回验证 → 提交。监控线程每秒检查调度器在位性、租约与 TTL;任何异常触发补偿回退,内核状态由 map 自证清除。事件链在此之上增

加自动通道:BPF 程序在 sched tracepoint 上测量每个 cgroup 的排队等待,只读泵汇总上报,执行服务依据人工授权的阈值决定是否调整权重。

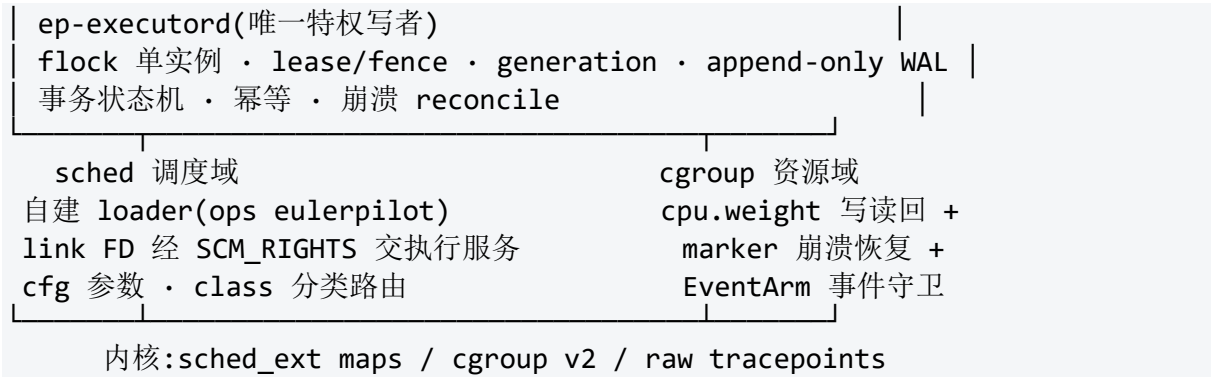
表 6 端到端流程(一次 apply)

步骤	执行者	产物/断言
1 提交	`ep apply --file F`	envelope + policy 一行 JSON;`req-*/txn-*` 标识
2 校验	执行服务	schema + 语义(切片关系、TTL/驻留、class⇔role)→ 违规 `REJECTED`
3 授权	执行服务	租约属主与 fence 检查、`expected_generation` 比对
4 目标解析	`TargetBinding`	`O_PATH|O_NOFOLLOW` FD + kernfs inode、pidfd + starttime
5 快照与日志	Journal	WAL `PREPARED`(含快照)后 fsync
6 生效	Skill	sched:loader 挂载 + cfg/class 写入;cgroup:`cpu.weight` 写入
7 读回验证	Skill	state/ops/enable_seq 等值判定;cgroup 文件读回
8 提交	执行服务	WAL `VERIFIED` → `COMMITTED`,世代号 +1
9 常驻监控	监控线程	50ms tick;1s 特征/在位(连续 3 次失败才回退)、2s 刷新与自动通道
10 回退	执行服务	`COMPENSATING` → 撤销 → 读回确认 → `ROLLED_BACK`

3.3 系统构成

三层结构,权限单向递减(详图与设计理由见 `docs/设计文档.md`):





3.4 主要量化结论

表 7 结论一览(条件随附,完整方法与边界见 docs/测试文档.md 第 7 章)

项目	数值	条件与出处
前台 goodput@SLO(C 固定专家 vs A0 默认)	GET **+1.83% [1.38, 2.26]** 20 胜 0 负;SET +1.39% [0.82, 1.58] 18/2	Redis 开环 60k rps、SLO 5ms、20 block 块内配对、冻结构建 (evidence/p2/flagship-rerun-20261025.txt)
p99 延迟变化	−39.6%(GET)/ −32.8%(SET)	同上
自适应臂 D vs A0	GET +1.74% [1.24, 2.19];SET +1.05% [0.59, 1.40]	同上;D 与 C 统计打平(−0.19% [−0.33, +0.14])
纯观测栈成本 A1 vs A0	GET −0.55% [−0.94, +0.14];SET −0.68% [−1.17, −0.19]	如实披露的负结果
收益是否静态 cgroup 倾斜可得	C vs A2 **+1.90% [1.63, 2.32]** 20/0	首轮矩阵 (evidence/p2/flagship-matrix-20261023.txt)
BASIC 数据面 B vs A0	GET +1.75% [1.45, 2.09] 10/0;p99 −40.8%	补充臂 (evidence/p2/barms-20261025.txt)
参考实现 E(schedpilotd)vs A0	GET +1.92% [0.94, 2.17] 10/0;SET 打平	新旧控制面一致性 (evidence/p2/earms-20261025.txt)
后台任务相对进度	0.998–1.006(**未受损**,非”被优化”)	全部矩阵轮次
事件泵自身开销	CPU 0.5% 单核;goodput 配对中位差 −0.010% [−0.049, +0.592]	40k rps、6 组配对 (evidence/p4/pump-overhead-20261025.txt)

项目	数值	条件与出处
事件观测吞吐	726,919 次 wakeup 追踪 / 723,525 条等待聚合 ≈ 12.1k 事件/s,丢弃 0	同上
故障恢复	fail-safe 矩阵 **17/17**,run8 + 三代冻结构建复跑 run9/10/11	`experiments/fail_safe_matrix_sp3.sh`、`evidence/p1/`
一键验收	r28/r29/r30 各六轮全部 rc=0;ctest 8/8(0 SKIP)	`scripts/accept_sp3_rounds.sh`
单元与设计契约	587 断言全过;schema 6 正例 / 27 反例强制	`tests/unit/`、`scripts/validate_design.py`
切换代价	挂载/卸载空窗实测 303–665ms	量化后落成 AutoPilot 三层抑制
门控的真实作用	把动作**推迟约 40s**(D 第 26 次轮询 vs Dng 第 6 次),25 次 deny 全为 FOREGROUND_P99_EXCEEDED	门控注入实验 (`evidence/p2/gate-injection-20261023.txt`)

归因链(比单个数字更重要):A1 −0.5%(纯观测栈)→ B +1.75%(BASIC 数据面)→ C +1.83%(class 专家)。class 路由配对消融为零(Cc−C GET −0.01% [−0.29, +0.24], 10/10),mixed-foreground 场景去掉 class 的 Dnc 与 D 同为 2/3 联合 SLO 达标—— **该负载上的收益来自数据面的切片与预算形态,class 声明提供的是可审计契约,不是性能开关**。这句话比 +1.83% 更有信息量。

3.5 阶段完成度

表 8 阶段与退出判定(`docs/IMPLEMENTATION_PLAN.md` 全表)

阶段	内容	退出判定	实际
P0 环境	SP3 实机、内核核验、参考数据面重建	attach/detach + smoke 通过	2026-10-21 完成
P1 静态闭环	控制面、loader、策略绑定、fail-safe	无第二写者、崩溃可恢复、A/B/C 无失速	2026-10-24 达成(fail-safe 17/17)
P2 自适应	感知、路由、门控、自动 apply	相位可观察、缺指标保守退化	2026-10-22~23 完成,门控收益量化为”延迟器”
P3 性能复现	参数冻结、正式矩	原始件 + 配对统计	10-23 首轮;10-25 冻

阶段	内容	退出判定	实际
	阵		结构建复现
P4 扩展与恢复	cgroup 动作域 + eBPF 事件链	一条真实 hook→决策→动作→恢复	10-24 动作域;10-25 感知端闭合
P5 交付	冻结、镜像、手册、彩排、验收	包校验全过	10-25 完成(镜像 14.6GiB)

4. 总体架构

表 9 模块清单

模块	位置	职责
ep-executord	src/executor/	唯一特权写者:事务、租约、世代号、WAL、监控与恢复
ep(CLI)	src/cli/main.cpp	用户接口,单请求单响应的 Unix socket 客户端
核心逻辑	src/core/	策略校验、目标绑定、特征窗、路由、SLO 门控、AutoPilot、事件判定
Skill 实现	src/skills/	sched / sched-ref / cgroup / mock 四种效果域
事件泵	src/evtmon/	只读排空 BPF 聚合 map,解析路径后经 event.observe 上报
调度数据面	sched/	BPF 调度器(ops eulerpilot)、loader、cfg/class 辅助、事件 tracing
契约	design/	5 个 schema + EventArm、6 个示例、接口清单
实验驱动	experiments/	旗舰矩阵、消融、fail-safe、演示、泵开销测量
测试	tests/	单元 + 8 项 CTest 集成
证据	evidence/	分阶段证据文件(每个含完整性与边界章节)
脚本	scripts/	构建、设计自检、验收、包

模块	位置	职责
		校验、演示、doctor

表 10 两个效果域对比

维度	sched 调度域	cgroup 资源域
策略 kind	SchedulingPolicy	CgroupPolicy
scope	scheduler-instance	cgroup-effects
内核对象	struct_ops 调度器 + pinned maps(sp_cfg/class_map 等)	cgroup v2 cpu.weight
生效方式	loader 注册后经 SCM_RIGHTS 交 link FD;cfg/class 由 ep-schedctl 写	写前快照、写后读回 (O_TRUNC 必需)
在位自证	/sys/kernel/sched_ext/state + ops + enable_seq 等值判定	文件内容读回
漂移纠正	cfg 每刷新周期再断言;class 条目按轮换抽样再断言	每刷新周期复查(文件读取代价低)
崩溃恢复	link FD 随进程死亡自动失效;pin 由同实例重启回收	marker 文件 cgroup-effects.json 恢复原值
事件驱动	不适用	EventArm 武装守卫
域不匹配	零副作用 REJECTED + error.code=UNSUPPORTED	同

表 11 运行时文件布局(<state-dir> 默认 /run/eulerpilot-v2/executor)

文件	作用
executor.sock	控制 socket,0600,SO_PEERCRED 限定同 uid
executor.pid	实例 PID
executor.lock	flock,单实例互斥
state.json	世代号、租约、fence(写失败仅降级为内存租约)
journal.jsonl	只追加 WAL,每次 append 后 fsync
sched-runtime.json	sched 域运行态(实例 id、pin、已分类条目)

文件	作用
sched-link.sock	loader 交 FD 的瞬时监听套接字
cgroup-effects.json	cgroup 域 marker(原值与动作 ID,崩溃恢复用)
mock/value.json	mock 域效果载体(测试用)
/sys/fs/bpf/eulerpilot-v2/<instance_id>/	每实例独立 pin 目录

表 12 内核与工具链依赖

项目	要求	检查手段
内核	6.6.0-schedpilot-sp3,CONFIG_SCHED_CLASS_EXT=y	scripts/doctor.py
BTF	/sys/kernel/btf/vmlinux 存在	同上
cgroup	v2 统一层次 + psi=1	启动参数与 stat -fc %T
libbpf	内核树静态库(bpftool ≥7.3)	构建参数 -DEP_LIBBPF_STATIC
权限	root(写 BPF map 与 cgroup)	socket 0600 + peer cred

5. 功能说明

5.1 调度策略管控

策略是 JSON 文档(design/schemas/scheduling-policy.schema.json),声明目标、专家档位、参数与安全约束;执行服务负责校验、生效、验证与回退。

表 13 关键字段与取值

字段	取值	语义
spec.mode	basic / class / adaptive	adaptive 在 apply 阶段直接拒绝(见 8.2)
spec.expert	safe-basic / latency-balanced / throughput-balanced / cache-local	白名单档位,不可自定义
spec.source	rule-template / offline-search / human / llm-proposal	非 human 必须过门控

字段	取值	语义
spec.targets[]	1–64 条,kind=cgroup/pid,role=FOREGROUND/BACKGROUND/NEUTRAL	角色必须显式声明,系统不猜
targets[].class	NORMAL / LAT / COMPUTE / CACHE / BG	class=BG 必须配 role=BACKGROUND
parameters.*_slice_ns	250000–10000000	LAT 预算 60% 经片长比表达,实测 57.9–58.5%
parameters.bg_vtime_pct	50–400	后台虚拟时间惩罚
spec.safety.policy_ttl_ms	10000–3600000	效果硬上限,到期自动回退
spec.safety.min_dwell_ms	5000–300000	切换驻留下限
spec.safety.max_foreground_p99_ms	1 – 60000(可选)	在线前向延迟绝对上限,单窗即判

写入路径要点:配置写入 pinned map 前快照、写后读回;分类条目按目标身份写入 class map,NORMAL 不写条目(防 PID 复用继承),成员迁出立即撤销并用 class-get 读回确认;每刷新周期轮换抽样一条受管条目,纠正越权修改(evidence/p1/class-drift-20261025.txt)。

5.2 cgroup 资源管控

CgroupPolicy 声明 1–8 个 cgroup 的 cpu.weight(1 – 10000)。执行服务按 kind 路由:cgroup 策略只能打到 --skill cgroup 的实例,反之亦然,拒绝时零副作用。

表 14 cgroup 域生命周期

阶段	行为	失败处置
validate	校验字段、路径合法性(拒绝 ./.. 段与重复路径)	SCHEMA_INVALID
snapshot	读当前值入快照	读不到即 fail-closed,不进入 apply
apply	写 cpu.weight(O_WRONLY|O_TRUNC)	写失败进 COMPENSATING
verify	文件读回与期望值比对	不符 → 回退并 VERIFY_FAILED
marker	<state-dir>/cgroup-effects.json 记录原值与	marker 写失败则不声称已生

阶段	行为	失败处置
	动作 ID	效
refresh	每周期复查,外部改值被纠正并记日志	纠正失败 → 自动回退
崩溃恢复	重启时按 marker 恢复原值	恢复失败保留现场并 RECOVERY_REQUIRED
叠加保护	效果在位时拒绝第二次 apply	REJECTED,不产生第二写者

5.3 事件驱动防护(R5 链路)

sched/events_trace.bpf.c 挂在 raw tracepoint(sched_wakeup/sched_wakeup_new/ sched_switch/sched_process_exit),按 cgroup kernfs id 聚合任务从唤醒到首次运行的等待;start_time 比对排除 PID 复用误配。只读泵 ep-evtmon 每窗口排空聚合 map、把 id 解析回路径并经 event.observe 上报,自身不写任何内核或文件状态。

表 15 EventArm 授权字段

字段	范围	含义
spec.watch	必须是活 cgroup 目录	被观察对象
threshold_wait_ms	1–60000	触发等待阈值
sustain_windows / release_windows	1–10	升权/回落所需连续窗口数
min_interval_ms / lease_ttl_ms	1000–3600000	动作最小间隔 / 守卫租约
policy_ttl_ms	10000–3600000	升权效果硬上限
action.cpu_weight	1–10000	升权目标值

判定与动作:EventArm 判定函数纯化(证据门 NONE/STALE/无事件/低于阈值 → 持续 N 窗超阈 → apply),动作走与人工策略完全相同的事务路径;回落 N 窗、TTL 到期、泵停止三条路径任一都触发补偿。同路径 cgroup 删除重建会使授权失效(WATCH_REBUILT), 权限不静默转移给新对象。真机六相时间线见 docs/测试文档.md 第 4 章。

5.4 感知、路由与门控

表 16 感知指标

指标	来源	有效性判定
cpu_busy_pct	/proc/stat 差分	样本数 ≥3 才算充分

指标	来源	有效性判定
load1	/proc/loadavg	带 age
psi_cpu_some_avg10	/proc/pressure/cpu	PSI 缺失时 valid=false
run_delay	—	本项目未采样(如实标注)

路由器按阈值 + 5s 滞回给出专家建议(仅建议)。SLO 门控分两半:服务半区读策略声明的延迟上限与后台进度下限,事件半区读泵观测;**两者都只能拒绝动作,不能放行**。比较类判定先声明分辨率:实测同状态 p99 窗间噪声极差/均值 46%(加载 30s 窗 CV 20.2%),当策略要求的敏感度不大于噪声时,判定直接报告 not run (docs/EXPERIMENT_PROTOCOL.md §5.1)。

表 17 AutoPilot 三层抑制

抑制层	参数	默认	作用
驻留	--auto-dwell-ms	60000	切换后最短保持时间
候选保持	--auto-candidate-hold-ms	15000	新档位需连续满足的时长
预算	--auto-budget-window-ms / --auto-budget-max-switches	600000 / 2	窗口内切换次数上限

AutoPilot 需显式 --auto-apply 开启,并要求租约交给 --auto-owner;切换代价 (空窗 303–665ms)与门控”延迟器”效应(约 40s)均已在真机量化。

5.5 故障恢复

17 类故障场景构成 fail-safe 矩阵,每类断言三件事:目标进程继续推进、内核状态由 map/文件自证清除、无本场景新增 pin。

表 18 fail-safe 条目(逐条细节见 docs/测试文档.md 第 6 章)

编号	注入的故障
S01 / S02	class / basic 模式挂载后回退,残余由内核 map 自证清除
S03	adaptive 模式在 apply 阶段被拒(设计上未启用,拒绝即其 fail-safe 形态)
S04 / S05	挂载中 SIGKILL 执行服务 / SIGKILL loader 进程
S06 / S07	租约 TTL 到期不续租 / 策略 TTL 到期

编号	注入的故障
S08 / S09	无效策略(未知字段、非法 class)/ 越界与类型错误
S10 / S11	裸请求世代号冲突 / 同状态目录启动第二实例
S12	外部越权改 cfg 与 class(改值、删除均被纠正)
S13	BG 成员迁出声明的 cgroup(撤销并读回确认)
S14	状态目录灌满 ENOSPC(仅内存租约完成拆除,新效应被拒)
S15	CPU 热插拔(本内核行为为注销调度器,系统检出并补偿)
S16	无法在 v2 构造的场景如实标注(PMU/心跳/PID 复用/TID)
S17	两步写入的第二步失败(补偿成功、世代号不推进、可干净重试)

结果:run8 与三代冻结构建复跑(run9/10/11)均 **17/17**。矩阵过程中暴露并修复的真实产品缺陷有两个——停止信号不清理 pin(新增 `Executor::shutdown()`)、盘满时回退被租约前置写挡死(拆除/建新方向不对称),详见 `docs/p1/P1_EXIT_REPORT.md`。

5.6 审计与溯源

- 每次变更在 `journal.jsonl` 留下 `PREPARED→APPLYING→VERIFYING→VERIFIED→COMMITTED` 或补偿路径的记录,崩溃后据尾行判定未完成事务;
- 幂等:同 `idempotency_key` 同内容重放返回首次结果,同键异内容拒绝;
- `PROVENANCE.md` 逐轮记录源码提交、产物 SHA256、BPF 对象哈希与迁移来源;
- 三代冻结构建:`ep-executord` 分别 `3693c9ac…`(gen-1,性能结论所指)、`35e80b99…`(gen-2,watch 身份加固)、`6f667b2e…`(gen-3,最终交付,含 cgroup 双写保护); gen-2/gen-3 的改动不在矩阵臂执行路径上(见 `evidence/p1/frozen-build-20261025.txt`)。

5.7 演示

`scripts/demo_sp3.sh` 八步时间线(约 5–6 分钟):契约校验 → 默认调度器基线 → 策略生效(内核自证)→ 扰动下的感知链应答 → 崩溃恢复 → cgroup 权重调整 → 事件驱动防护(升权与补偿)→ 干净收尾。最终形态连续三次彩排 PASS,每次收尾 `state=disabled`、`pins=0`;失败也保留现场目录与 FAIL 行(见 `evidence/p5/demo-rehearsals-20261025.txt`)。

6. 关键设计决策

表 19 决策记录(完整取舍讨论见 docs/v2_redesign_2026.md 与 docs/设计文档.md 第 8 章)

决策	备选	选择理由与证据
唯一写者架构	各组件自行写内核	所有变更走同一事务通道,第二写者在结构上无法构造
link FD 经 SCM_RIGHTS 移交	loader 常驻	loader 挂载后即退出,执行服务崩溃即分离,不留孤儿调度器
失效方向不对称	写失败一律拒绝操作	拆效应永远放行、建新效应要求可持久化审计;盘满时仍能安全回退(S14)
BG 与 LAT/COMPUTE/CACHE 正交	按 CPU 占用推断角色	业务角色来自显式授权,运行特征来自测量;禁止把陌生高 CPU 任务降为 BG
判定顺序 权限→证据→抑制	抑制优先	顺序本身是契约;抑制排在证据之后,保证”没证据就不动”
观测只能收紧	观测可放行	测量数据有噪声与断供两种失败模式,放行会把误报变成动作
比较类判定声明分辨率	直接判	同状态 p99 窗间噪声 46%,预算 5% 的判定是噪声放大器
enable_seq 等值判定 + 发布等待	计数器递增即信任	内核在 state 可读之后才递增计数器(kernel/sched/ext.c:5503–5518),不等发布会误报
绑核任务直投本机 local DSQ	唤醒 idle CPU 等拉取	6.6 内核把不允许的拉取改投全局 DSQ;修复前 6/6 失败 → 3×90s 零失速
份额按片长比表达	直接写百分比	份额由片长比决定,lat_slice=comp_slice×pct/(100−pct) 后 60% 预算实测 57.9–58.5%
跨域失败按 saga 处理	承诺原子事务	内核多子系统之间不存在原

决策	备选	选择理由与证据
		子事务;补偿顺序执行,失败保留现场并 RECOVERY_REQUIRED
负结果入档	只报有利轮次	失败轮与作废轮全部保留;A1 成本、@2ms 无优势均写入正文

7. 运行环境与交付物

表 20 环境要求

项目	要求
操作系统	openEuler 24.03 LTS-SP3(唯一验收级系统)
内核	6.6.0-schedpilot-sp3(sched_ext 启用,源码与 config 哈希入档)
规格	8 vCPU / 16 GiB(验收配置)
权限	root
构建依赖	cmake ≥3.20、GCC 13+/Clang 17、内核树静态 libbpf、bpftool ≥7.3、python3(设计校验用 jsonschema)
实验依赖	redis-server / redis-benchmark(旗舰负载)

表 21 交付物

交付物	内容	校验
源码仓库	本仓库(含契约、测试、实验驱动与汇总证据)	scripts/verify_package_sp3.sh
虚拟机镜像	schedpilot-sp3-20261025.qcow2(虚拟 80GiB / 压缩 14.6GiB)	SHA256 d9dd5030…,全值见 PROVENANCE.md
域定义与安装应答	domain.xml、ks.cfg、README.txt、SHA256SUMS	与镜像同包
冻结二进制	ep-executord / ep / ep-sched-loader / ep-schedctl / ep-evtmon / events_trace.bpf.o	哈希表见 docs/部署文档.md 第 2 章

交付物	内容	校验
文档集	本文 + 设计/用户/部署/测试四份(md 源 + docx 交付)	修订记录随文档

表 22 仓库结构

```
README.md                    评委入口 + 题目信息 + 状态总览
docs/                        五份交付文档 + 参赛报告 + 验收报告 + 阶段报告
design/                      schema、示例、接口清单
src/                         cli / core / executor / skills / evtmon
sched/                       BPF 调度器、loader、cfg 辅助、事件 tracing
experiments/                 旗舰矩阵、消融、fail-safe、演示、开销测量
tests/                       单元 + 8 项集成(CTest)
evidence/                    p0/p1/p2/p4/p5 证据文件与 SHA256SUMS
scripts/                     构建、设计自检、验收、包校验、演示、doctor
third_party/                 nlohmann/json v3.11.3(MIT,哈希入档)
LICENSE / NOTICE             GPL-2.0 与组件边界
```

8. 适用范围与不支持项

8.1 支持矩阵

表 23 能力支持度

场景	支持度	条件
单机 Redis 开环负载下的调度策略闭环	支持并实测	8 vCPU、SLO 5ms、20 block 配对
其他负载类型的性能收益	**未验证**	单机单负载,不外推
后台任务保护	支持	相对进度 0.998 – 1.006,结论是”未受损”非”被优化”
cgroup cpu.weight 管控	支持	仅该旋钮;委派权限缺失时须用 systemd scope
事件驱动自动调权	支持	泵在线、授权有效、cgroup 未重建
跨机/集群验证	**UNSUPPORTED**	备用机 SP4 为 cgroup v1 且无 PSI
上游 scx 调度器对照(X 臂)	**UNSUPPORTED**	上游主线已 Rust 化且目标内核高于本机 6.6
adaptive 模式	**UNSUPPORTED by design**	apply 阶段直接拒绝
心跳降级	**UNSUPPORTED by design**	heartbeat_ns 仅 adaptive

场景	支持度	条件
		路径读取
PMU 分类	**UNSUPPORTED**	无 PMU 消费者,无路径可测
TID 粒度目标	超出范围	class map 以 tgid 为键

8.2 硬边界(不可回避)

- **性能结论的条件**:单机、单负载(Redis)、单 SLO 设定(5ms);阈值敏感性同报 ——@1ms C GET +2.5%、@2ms 各臂无优势甚至略负、@10ms ≈+0.6%;收益集中在 5ms 以上的远尾。
- **一次旗舰矩阵约 3.7 小时**,逐请求原始件(约 5.8GB)留在测试机 `/root/epv2-evidence/`,仓库入库汇总、`comparisons.csv` 与 SHA256SUMS。
- **观测分辨率**:p99 窗间噪声 46%,不能驱动自动判定;敏感度低于噪声的判定明报 `not run`。
- **内核行为约束**:Linux 同时只允许一个 sched_ext 调度器(第二次注册 EBUSY); CPU 下线会注销调度器(参考实现同样如此);切换存在 303–665ms 空窗。
- **stall 类缺陷未穷尽**:17 条目里没有”排队任务卡死”的主动构造,该根因由独立实验定位修复,不等同于覆盖。

9. 结论与后续工作

9.1 结论

1. **赛题 R1–R10 全部达成**,其中 R4/R8 带明示边界、R6 由消融支撑(判定与逐条依据见 `docs/ACCEPTANCE_20261025.md`)。
2. 系统价值主张成立且可验证:**自适应能力本身几乎免费**(D 相对 C 统计打平, −0.19%),**观测栈有可测成本**(A1 −0.55%~−0.82%,如实披露),**收益来自数据面形态而非 class 标签**(B/C/class-routing 三条线互证)。
3. 工程可靠性以矩阵形式证明:17 类故障在冻结交付构建上 17/17,三代构建各跑一轮。
4. 扩展能力以实际接入证明:cgroup 动作域与 eBPF 事件链在**未修改核心事务代码**的前提下并入,成为第 7、8 个必测集成项。

9.2 未完成与后续工作

表 24 后续项(按优先级)

项	现状	下一步	完成判据
事件链在旗舰矩阵下的收益量化	泵开销已测,收益未测	在饿死场景加入 F 臂	与 C/D 同样口径的配对结论
多负载类型泛化	仅 Redis 一种	增加计算密集与混合负载轮次	每种负载独立预注册并出数

项	现状	下一步	完成判据
map 饱和场景	未构造(>4096 cgroup)	补故障矩阵条目	如实标注 PASS/SKIP
BPF 聚合 map 容量假设	4096 上限,已说明	需要时提高上限并复测丢弃计数	丢弃计数仍为 0
跨机验证	UNSUPPORTED	需一台 cgroup v2 + PSI 的第二台 SP3	双臂复现同结论
镜像提交方式	已制作,待确认交付形态	与组委会确认 14.6GiB 的提交方式	—

10. 术语表

表 25 术语

术语	含义
sched_ext / scx	Linux 6.6 起的 BPF 调度器框架
struct_ops	用 BPF 程序实现内核接口_ops 结构的机制,调度器经它注册
DSQ	调度器内的派发队列(deferred scheduling queue)
ops eulerpilot	本项目自建调度器的注册名(/sys/kernel/sched_ext/ops)
lease / fence / generation	租约(写权限时限)/ 栅栏(过期凭证识别)/ 世代号(已提交变更计数)
WAL	只追加的写前日志(journal.jsonl),崩溃后据此 reconcile
TargetBinding	目标身份绑定:O_PATH FD + kernfs inode、pidfd + starttime
FeatureWindow	窗口化的主机特征及其有效性/年龄/来源
goodput@SLO	延迟不超过 SLO 的成功请求数/秒,按逐请求原始数据统计
块内配对	同一实验块内各臂共享初始条件,差值做统计,消除跨块方差
EventArm	事件驱动动作的人工授权声明
WATCH_REBUILT	被看 cgroup 重建导致授权失效的状态

术语	含义
UNSUPPORTED / SKIP	能力缺失与前置条件不满足的如实标注,与 PASS 并列呈现
fail-safe	任何故障都向”没有策略”的安全方向回退
saga	跨域变更的补偿式恢复流程,不承诺内核多子系统原子性

11. 文档索引

表 26 相关文档

文档	用途
docs/设计文档.md	架构与模块的完整设计说明
docs/用户手册.md	CLI、策略编写、状态解读、排障速查
docs/部署文档.md	镜像部署、源码构建、部署验证、升级回滚
docs/测试文档.md	六层测试体系、fail-safe 17 条目、性能方法与结果
docs/REPORT.md	按大赛文档大纲组织的参赛文档
docs/ACCEPTANCE_20261025.md	R1–R10 逐条验收判定与边界
docs/MANUAL_SP3.md	构建配方与日常命令速查
docs/EXPERIMENT_PROTOCOL.md	实验方法预注册协议
docs/IMPLEMENTATION_PLAN.md	实施计划全表(逐项带证据路径)
docs/p1/P1_EXIT_REPORT.md	P1 退出门槛判定与覆盖范围
docs/v2_redesign_2026.md	完整设计总纲与取舍讨论
docs/HANDOVER_20261024.md	交接材料(进度、天花板、约定)
design/INTERFACES.md	接口与对象生命周期契约
PROVENANCE.md	逐轮二进制哈希、来源与公开化重写披露
evidence/	各阶段证据文件(每个含完整性与边界章节)

12. 修订记录

版本	日期	内容	作者

版本	日期	内容	作者
v1.0	2026-10-25	随交付创建	三驱兄弟
v1.1	2026-10-25	扩充:阅读路径、R1－R10 映射、端到端流程表、两域对比、运行时文件布局、EventArm/AutoPilot 参数表、支持矩阵、后续项;数字统一对齐冻结构建复现轮	三驱兄弟